

AI 기반 성장 유망 매장 스코어링 시스템

비전몽(vision - 夢)

20211459 이학주

20211462 이민재

20211474 김진서

20211486 박준규

Contents

01. 서론

02. 가설 설정

03. 데이터 수집

04. 제안 방법론

05. EDA

06. 모델링

07. 결론

01 서론 - 문제 배경

기존 외식업 매장 평가 방식의 한계

- 프랜차이즈 본사나 투자 기관이 매장의 가치를 평가하는 정량적·객관적 평가 기준의 부재

방대한 F&B 매장 데이터 축적에 따른 가치 창출의 필요성

- 기존의 구독 형태의 서비스 제공을 넘어선 새로운 비즈니스 가치 창출
- 성장 유망 매장의 조기 식별을 통한 투자 검토 효율화

01 서론 - 목표 정의

AI 기반의 성장 유망 매장 스코어링 모델

비즈니스 목표

- 르몽이 가진 고객 DB를 이용해 **투자 검토 후보를 선별하는 AI 모델** 개발
- 유망 매장 선별 → 솔루션 도입으로 매장 성장 지원 → 지분 매각 → 펀드의 순환 구조 형성

기술 및 구현 목표

- 현재 가치가 낮아 투자 가성비가 뛰어나면서도, **미래 성장 잠재력이 높은** 후보 매장을 예측
- 실제 데이터 기반 **매장 성장·하락 패턴 분석**을 통한 핵심 변수 도출

02 가설 설정

1) 성장 신호 포착

최근 리뷰·주문·매출의 흐름이 개선되는 매장은 동월 대비 성장 후보일 가능성이 있다

주요 변수

- 주문·매출 변동성: 최근 3개월 주문·매출의 표준편차 기반 변동 폭
- 리뷰 수 변화 흐름: 최근 3개월 rolling 리뷰 수 추이

2) 고객 만족도 누적

긍정 반응과 재방문 신호가 누적되고 부정 반응이 낮은 매장은 성장 후보일 가능성이 있다

주요 변수

- 재방문 추정 리뷰 수·비율: 동일 작성자 재방문 리뷰 수 및 전체 리뷰 대비 비율
- 리뷰 텍스트 기반 고객 반응 변수 수치화

3) 운영 역량

고객 반응에 꾸준히 대응하는 매장은 성장 신호가 실제 성과로 연결될 가능성이 있다

주요 변수

- 답글률 및 답글 유형: 전체 리뷰 대비 사장님 답글 비율, 정형·맞춤형 답글 유형
- 운영 관련 관리 신호: 답글 활동 빈도 기반 매장 운영 적극성 지표

4) 평판·상권 교차 검증 / 외부 환경 리스크 보완

외부 플랫폼 평판과 상권·가격 환경은 투자 검토 후보의 리스크와 설명력을 보완할 수 있다

주요 변수

- 네이버 방문자 리뷰·블로그 리뷰: 매장별 방문자 리뷰 수 및 블로그 리뷰 수
- 메뉴 등록, 영업시간, 배달·포장·예약 여부: 매장 정보 등록 항목별 노출 여부
- 동일 업종 점포 수, 개·폐업 수, 폐업률
- 업종·지역 대비 가격 수준

03 데이터 수집

외부 상권 데이터 목록

- 소상공인시장진흥공단_상가(상권)정보
- 업종별 인허가 정보: 일반음식점

식별/매칭: 시도, 시군구, 행정동명, 도로명주소, 지번주소

상권 규모: 시군구별 전체 음식점 수, 시군구별 동일 업종 점포 수

개·폐업 지표: 인허가일자, 폐업일자, 영업상태, 최근 1년·3년 개업 수, 폐업 수, 폐업률

업종/경쟁 지표: 상권업종분류명, 업태구분명, 동일 업종 밀집도, 경쟁강도지수

상권 안정성: 상권안정성지수, 상권리스크지수

03 데이터 수집

네이버 플레이스 데이터 목록

매장 매칭 정보: platform_shop_id, 매장명, 주소, 업종, 네이버 플레이스 ID

리뷰 평판 정보: 방문자 리뷰 수, 리뷰 원문, 리뷰 작성일, 긍정·부정·중립·재방문 리뷰 수

매장 관리 정보: 전화번호, 영업시간, 메뉴 등록 여부

서비스 옵션 정보: 배달, 포장, 예약 가능 여부

수집 상태 정보: 매칭 성공 여부, 리뷰 수집 성공 여부, 접근 차단 여부

03 데이터 수집 - 가공 및 변수화

외부 상권 데이터

- 매장 주소에서 시도·시군구·읍면동 값을 추출한 뒤, 상권 데이터의 지역 단위와 매칭
- 전체 음식점 수, 동일 업종 점포 수, 개업 수, 폐업 수, 폐업률 등의 파생 변수 생성
- 생성된 상권 변수는 platform_shop_id 기준으로 기업 데이터와 병합

네이버 플레이스

- 기업 데이터의 매장명, 주소, 업종, 브랜드명을 기준으로 네이버 플레이스 후보 검색
- 매장명 완전 일치보다 주소 일치 여부와 브랜드 계열 일치를 우선하여 최종 매칭
- 리뷰 원문과 작성일을 수집한 뒤, platform_shop_id와 year_month 기준으로 월별 변수화
- 고정 기간 집계 대신 현재월 포함 최근 3개월 rolling 변수로 재구성하여 시간 정합성 확보

03 데이터 수집 예시: 외부·보조 데이터 병합 현황

데이터	수집·정제 규모	수집 기간	모델 병합	생성 변수	활용 목적
외부 상권	2,691,377 → 842,988	2025년 12월 시점 등록 상가 현황	1,238개 내부 매장 (99.36%)	총 5개	매장 자체 지표만으로 설명하 기 어려운 지역 상권 차이를 통제하는 변수
네이버 플레이스	• 검색 1,246 • 방문자 리뷰 19,184 • 블로그 1,677 → 플레이스 매칭 1,194	2024.11 ~ 2025.02	1,194개 매장 (95.83%)	총 1개	핵심 결정 신호가 아니라 외부 평판 보조 신호로 사용

03 데이터 수집 예시: 외부·보조 데이터 주요 파생 변수

구분	변수명	설명	해석
상권	경쟁강도지수	동일 업종 점포 수·폐업률 등을 결합해 직접 설계한 상권 경쟁 강도 지수	수치가 높을수록 경쟁이 치열한 환경으로, 성장 난이도 판단에 활용
상권	경쟁보정_매출액	월별 매출액을 경쟁강도지수로 나눠 경쟁 환경을 보정한 매출	경쟁이 심한 지역에서 높은 매출을 내는 매장을 상대적으로 높게 평가
상권	시군구_동일업종점포수	해당 매장이 속한 시군구 내 같은 업종 매장 수	광역 단위 경쟁 포화도를 나타내며, 수치가 클수록 경쟁 압력이 높음
상권	행정동_동일업종점포수	해당 매장이 속한 행정동 내 같은 업종 매장 수	근거리 직접 경쟁 강도를 측정하는 세밀한 단위의 경쟁 지표
상권	행정동_최근3년폐업률	최근 3년간 해당 행정동 음식점 폐업 비율	폐업률이 높은 상권일수록 외부 환경 리스크가 크다고 판단
네이버 플레이스	naver_roll3ext_positive_ratio	네이버 플레이스 최근 3개월 리뷰 중 긍정 리뷰 비율	배달앱 외 방문 고객의 만족도를 반영하는 외부 평판 신호

04 제안 방법론

목표

매장의 과거 N개월 리뷰·외부평판·운영 데이터를 통해,
동월 대비 성장 유망 후보를 우선순위화하는 스코어링 모델 설계

1단계. 월별 패널 데이터 구축

- 주문·매출·리뷰·답글·매장 정보를 platform_shop_id와 year_month 기준으로 통합
- 최근 3개월 주문·매출 흐름과 재방문 추정 변수 생성
- 매장 단위 시계열 패널을 구성하여 월별 단위 시간 정합성 확보
- 리뷰 텍스트 기반 고객 반응 변수 수치화

04 제안 방법론

2단계. 외부 보조 변수 결합

- 상권 데이터로 지역 경쟁도와 안정성 변수 생성
- 네이버 플레이스 데이터를 최근 3개월 rolling 변수로 재구성
- 가격 경쟁력 변수를 보조 설명 변수로 추가

외부 평판·환경 데이터 기반 **파생변수 생성** 및 **데이터셋 결합**

3단계. 누수 제거 및 안전 입력 변수 구성

- 6개월후 미래 컬럼과 라벨 파생 컬럼을 입력 변수에서 제외
- 모델 성능 극대화보다 실제 적용 가능한 검증 구조를 우선
- 재현 가능한 후보 추천 파이프라인 확보

미래 정보 누수 방지 및 학습·검증 입력 변수 분리 설계

04 제안 방법론 - 모델 학습 및 검증 방식

라벨 정의

- 입력: 과거 N개월의 주문·매출·리뷰·운영 지표 + 외부 데이터
- 정답 라벨: 동일 year_month 내 매장끼리 6개월 후 매출성장률을 비교하여 상위 25%는 성장, 하위 25%는 하락, 나머지는 유지로 정의
 - 절대 성장률이 아닌, 동월 대비 상대 성장 유망성을 의미

→ 동월 대비 성장 유망성 기준의 상대 라벨링

모델 학습

- XGBoost 기반 3분류 지도학습으로 성장·유지·하락 확률 예측
- 정형 데이터와 파생변수 간 비선형 관계 학습에 적합
- 각 클래스 확률 출력이 가능하여 성장 라벨 예측 확률(prob_growth)을 최종 후보 추천 score로 사용

04 제안 방법론 - 모델 학습 및 검증 방식

후보 추천

- prob_growth 기준으로 매장을 정렬하여 Top-K 투자 검토 후보를 선정
- 추천 수는 Top-10, Top-20 등 검토 목적에 따라 조정 가능

검증 방식

- train·valid·test 분리 후 test는 최종 검증 전용으로 사용
- Top-K Precision, TP, FP, Lift를 기준으로 추천 후보의 신뢰도 평가

05 EDA — 데이터셋 구성

매장-월 단위 패널 데이터 구축


- 분석 단위 : platform_shop_id x year_month
- 주문·매출·리뷰·상권·가격 정보를 기준월 단위로 통합
→ 특정 매장의 특정 월 상태를 하나의 관측치로 정의

시간 순서 기반 train-valid-test 분리

- train : 2024-11 ~ 2025-04 (723건)
- valid : 2025-05 (217건)
- test : 2025-06 (702건)

최종 모델 입력 변수 구성

- 최종 모델은 29개 입력 변수 사용
- 입력 변수는 기준월 t 시점 또는 t 시점 이전 정보만 사용
→ t+6 시점 매출 및 미래 성장률은 모델 입력에서 제외



항목	값
분석 단위	platform_shop_id x year_month
분석 기간	2024-11 ~ 2025-06 (8개월)
전체 샘플 수	1,642건
고유 매장 수	712개
모델 입력 변수	29개, 수치형 25개 + 범주형 4개


05 EDA — 라벨 정의 및 분포

6개월 후 매출성장률 기반 라벨 생성

- 기준월 t시점의 매출과 6개월 후의 매출을 비교하여 성장률 계산
- 동일 year_month 내 매장들의 성장률을 기준으로 상대 순위화

라벨 분포는 25 / 50 / 25 구조로 안정적

- 전체 1,642건 중 성장 414건, 유지 814건, 하락 414건
- train, valid, test에서도 유사한 라벨 비율 유지
- 특정 split에 성장/하락 라벨이 치우치지 않음
→ 모델 검증 시 라벨 분포 왜곡 가능성 낮음



05 EDA — 매출·주문 흐름


"매출 규모가 클수록 성장하는가, 아니면 흐름이 중요한가?"

매출이 큰 매장이 항상 더 성장하는 것은 아니다.

- 하락(956만원) > 유지(839만원) > 성장(462만원)
→ 잘 팔리는 매장이 오히려 하락 그룹
- 성장 라벨이 같은 달 기준 상위 25%여서 생기는 구조
- 이번 데이터에서는 현재 매출액만으로 6개월 뒤 성장 여부를 판단하기 어려움

6개월 후 성장률은 성장 그룹에서 가장 높았다.

- 성장 그룹은 6개월 뒤 매출이 54% 오름
- 하락 그룹은 같은 기간 매출이 72% 빠짐
- 일부 빠르게 성장한 매장이 성장 그룹의 평균을 올림



왼쪽 차트 — 기준 시점(t, 2024.11~2025.06)에 측정한 월별 매출액
오른쪽 차트 — 그 매장이 6개월 후(t+6, 2025.05~2025.12)에 얼마나 성장했는지

05 EDA — 리뷰·재방문 반응


"긍정적 고객 반응이 많은 매장이 성장으로 이어지는가?"

재방문 비율은 성장 그룹에서 오히려 낮다.

- 성장(0.09) < 하락(0.11)
→ 재방문이 많은 매장이 오히려 성장하지 않음
- 재방문(단골)이 많다는 건 매출이 이미 고정된 안정기라고 볼 수 있음
- 성장 그룹이 기존 고객 재방문보다 신규 고객 유입의 영향을 더 받을 가능성이 있음

긍정 리뷰 비율만으로는 구분이 어렵다.

- 하락(0.51) = 성장(0.51) < 유지(0.53)
→ 세 그룹 숫자가 거의 같음
- 리뷰 비율 추이를 보고 싶었지만 결측값이 많아 사용하기 어려움
- 같은 달·같은 업종 안에서 상대적으로 높은지 정도만 참고



05 EDA — 최근 3개월 변화 흐름


“최근 변화 방향이 미래 성장을 예측하는가?”

성장 그룹은 최근 3개월 매출 변동이 크다.

- 성장(0.34) > 하락(0.33) > 유지(0.30)
- 성장 중인 매장은 매출이 오르락내리락하는 변화 과정에 있음
- 매출이 안정적인 매장이 성장하는 게 아니라, 변동이 큰 매장이 성장 그룹에 들어감

최근 매출 증가 폭만으로는 성장 판단이 어렵다.

- 하락(325만원) > 유지(257만원) > 성장(115만원)
— 기울기가 더 가파른 게 오히려 하락 그룹
- 하락 그룹은 과거에 잘 팔리다가 지금 내려오는 중이라 기울기가 크게 나옴
- 낮은 매출에서 조금씩 좋아진 매장이 성장 그룹에 들어감



05 EDA — 상권·경쟁 환경


"경쟁이 심한 지역에 있을수록 성장이 어려운가?"

경쟁이 큰 지역의 매장이 성장 그룹에 더 많이 나타난다.

- 성장(0.21) > 유지(0.17) >> 하락(0.10)
- 하락 그룹은 경쟁강도지수가 거의 0에 몰려 있음
- 경쟁이 큰 지역은 동시에 수요가 큰 지역일 가능성이 있음
- 조용한 독점 상권보다 경쟁이 있는 곳에서 더 잘 팔렸음

행정동 최근 3년 폐업률 — 세 그룹 간 차이가 거의 없다.

- 세 그룹 모두 0.23~0.24로 평균만 보면 거의 같음
- 폐업률 하나만 보면 차이가 작음



05 EDA — 가격 경쟁력


"가격이 낮은 매장이 성장에 유리한가?"

동업종·지역 대비 가격 위치 — 하락 그룹이 상대적으로 비싸다.

- 하락(0.78) > 유지(0.73) > 성장(0.71)
(0에 가까울수록 저렴, 1에 가까울수록 비쌈 — 같은 업종·지역 기준)
- 세 그룹 차이가 크지 않아 단독 신호는 약한 편
- 성장 그룹이 같은 업종·지역 내에서 비교적 저렴한 위치에 있었음

왜 절대 가격 대신 백분위를 썼나

- 치킨·피자·죽집 평균 메뉴가 모두 12,000~13,000대로 비슷하지만
각 업종 안에서의 위치는 완전히 다름
- 백분위로 변환하면 업종·지역 차이가 통제된 상태에서
"이 매장이 상대적으로 비싼지 저렴한지"를 공정하게 비교 가능



05 EDA 기반 모델링 방향

단순 평점보다 변동성 기반 최근 3개월 변화 흐름 입력 변수

- 리뷰수·주문수 기울기: 결측 69% + SHAP 중요도 낮아 제외
→ 변동계수로 대체
- 매출기울기: 결측 69%이나 SHAP 중요도 15위 → 학습 시 중앙값 대체 후 포함
- 절대적 증감보다 변동의 안정성·일관성이 성장 예측에 더 유효함을 확인

답글률·재방문 비율 실제 채택

- 최근3개월_평균답글률, 리뷰_주문비율, 누적_재방문추정고객비율 최종 포함
- SHAP 분석 결과 재방문 추정 비율이 성장 라벨 예측에 유의미하게 기여
- 답글 유형보다 답글률 자체가 모델 내 변별력이 높은 것으로 확인

외부 평판 신호(네이버 플레이스)로 대체

- 키워드 추출 방식 대신 naver_roll3ext_positive_ratio (긍정 리뷰 비율) 최종 채택
- Growth Score 시그널: 기울기 기반(결측 69%) → 동월·동업종 퍼센타일(결측 0%)로 대체
- 배달앱 리뷰와 독립적인 방문 고객 반응 채널을 추가함으로써 보조 신호 강화

업종·지역·상권 변수 실제 포함

- 범주형 통제 변수: category_name, sido, sigungu, dong 4개 전량 포함
- 상권 통제: 경쟁강도지수, 시군구·행정동 동일업종점포수, 행정동_최근3년폐업률 5개 채택


06 모델링 - Baseline 모델과 한계

기존 Baseline 모델 구조

- XGBoost 기반 3-class 분류 모델 사용
- 입력 변수 195개 기반으로 성장/유지/하락 확률 예측
- 최종 추천 점수는 성장 라벨 예측 확률(prob_growth) 사용
- prob_growth 기준으로 매장을 정렬하여 Top-K 후보 추천

Baseline에서 확인된 한계

- 성장 후보를 넓게 잡는 경향으로 Recall은 높았지만, Precision 개선 필요
- 추천 목적에서는 “모든 성장 후보를 많이 찾는 것” 보다 “상위 후보가 실제 성장인지”가 핵심
- 따라서 모델 성능 평가는 일반 분류 지표보다 Top-K Precision 중심으로 전환




지표	값
Growth Precision	0.3649
Growth Recall	0.8977
Growth F1	0.5189

06 모델링 - 1차 개선 실험 : Score 산출 방식 실험

문제 인식

- Baseline 모델은 성장 후보를 넓게 포착하지만, 실제 성장 매장 대비 예측 수가 많아 추천 후보의 정밀도가 낮아질 수 있음
→ 성장 라벨 예측 확률 기반 추천 score를 재정의하여 Top-K 후보 선별 성능 개선 가능성을 검토

실험 구분	Score 산출 방식	목적	결과
기본 score	prob_growth	성장 확률이 높은 매장을 우선 추천	Top-K 성능이 가장 안정적
하락 위험 보정	prob_growth - 1.5 x prob_decline	하락 가능성이 높은 후보를 낮게 조정	CV 일부 개선 test Top-10은 감소
가설 기반 blending	$w1 \times \text{prob_growth}$ + $w2 \times \text{매출} \cdot \text{주문}$ + $w3 \times \text{리뷰}$ + $w4 \times \text{상권}$ + $w5 \times \text{가격}$	모델 확률에 도메인 가설 신호 추가	최적 조합이 prob_growth 로 수렴



결과

- 하락 위험 보정 및 가설 기반 blending 실험 결과 기본 score 보다 성능이 감소하거나 기존 score 산출 방식에 수렴하므로 기존 score 산출 방식 채택

06 모델링 - 2차 개선 실험 : Feature 수 축소

문제 인식


- 195개 입력 변수 사용 시 Train 성능은 높지만 Test P@20 = 0.45로 급락
- 학습 데이터 약 700행 대비 입력 변수 수 과다
→ 과적합 발생
- 상관관계 높은 중복 입력 변수들이 모델에 노이즈로 작용

Step 1.

- 상관관계 제거 상관계수 0.80 이상인 입력 변수 쌍에서 SHAP 중요도가 낮은 쪽 제거
- 195개 → 84개

Step 2.


- SHAP 중요도 필터링 성장 클래스 예측에 실제로 기여하는 상위 25개만 선택
- 업종·지역이 다르면 성장 패턴이 다를 수 있으므로 이 차이를 구분해서 학습할 수 있도록 통제 변수로 업종·지역 범주형 4개 추가 활용



06 최종 모델: 29개 Feature XGBoost

- 피쳐 수를 195개에서 29개로 줄였더니 오히려 성능이 올라감 (CV Score: 0.626 → 0.675)
- 가격·매출·최근 3개월 변화 흐름·상관·리뷰 5가지 신호를 균형 있게 포함

알고리즘	XGBoost 3-class (multi:softprob)
입력 변수 수	29개
입력 변수 선택	corr_thr=0.80 + SHAP top-25
n_estimators	140
max_depth	3
learning_rate	0.06
CV 전략	Expanding Window 4-Fold
CV Score	0.675



06 Top-K 성능 비교 / 최종 모델의 추천 성능과 해석

K	TP	FP	Precision	Recall	Lift
Top-3	2	1	66.70%	1.10%	2.66
Top-5	3	2	60.00%	1.70%	2.39
Top-10	4	6	40.00%	2.30%	1.6
Top-15	7	8	46.70%	4.00%	1.86
Top-20	8	12	40.00%	4.50%	1.6
Top-50	17	33	34.00%	9.70%	1.36
유지율 (P@20/P@5)		66.70%			

① Top-5에서 60% — 실용적 투자 검토 구간

- 5개 추천 중 3개가 실제 성장 매장 → 랜덤 대비 2.4배
- 투자 담당자가 5개만 검토해도 높은 적중률 확보

② Top-15에서 반등(47%) — 비단조 패턴

- Top-7~10 구간에서 일시 하락 후 Top-15에서 반등
- 성장 매장이 중간 순위에도 분산 분포 → 상위 15개 검토 추천

③ 전 구간 랜덤 대비 1.4배 이상 유지

- Top-50까지도 Lift = 1.36x → 모델 유효성 전 구간 확인
- K가 커질수록 FP 비중 증가 → Top-5~15 집중 활용 권장



테스트 성장 매장 전체: 176개

랜덤 추천 기준선: 25.1%

07 결론

1. 달성한 것

- AI 기반 성장 유망 매장 스코어링 시스템 구축 완료
- 기업 제공 데이터 + 외부 공공 데이터 통합
* (소상공인진흥공단, 네이버 플레이스)
- XGBoost 3-class 모델 + Growth Score 설계
- Top-5 추천 정밀도 60% → 랜덤 대비 2.4배 효율

2. 핵심 발견

- ① 성장을 예측하는 핵심 신호는 "가격 구조의 일관성"
 - SHAP 1위: 저가 이상 메뉴 수 → 합리적 가격 유지 매장이 성장에 유리
- ② 절대 매출이 아닌 상대적 흐름이 중요
 - 매출이 높은 대형 매장이 오히려 하락 → 동월 상대 성장률이 실질 지표
- ③ 피처가 적을수록 일반화 성능이 높아짐
 - 195개 → 29개 축소 시 CV 0.626 → 0.675 향상

07 결론

3. 한계

- ① Top-K가 커질수록 정밀도 하락 (구조적 한계)
 - Top-5: 60% → Top-20: 40% → K 확장 시 FP 증가 불가피
- ② 학습-테스트 분포 차이 (Covariate Shift)
 - 테스트 매장의 79%가 신규 등장 → 이전 달 데이터 없음
 - 최근 3개월 변화 흐름 입력 변수의 결측 69%
→ 보조 신호 무력화
- ③ 데이터 규모 제한
 - 학습 데이터 약 700행 → 소규모 데이터 특성상 과적합 위험 존재

4. 향후 과제

- 데이터 누적 시 모델 재학습 → 시간이 지날수록 성능 안정화 기대
- 더 많은 외부 데이터 확보 (배달앱 주문 트렌드, 소셜 미디어 등)
- 카테고리별 특화 모델 분리 검토 (업종마다 성장 패턴 상이)

감사합니다.
