



추정 득점 예측 모델을 통한 팀별 최적 라인업 추천

데이터톤 퍼펙트게임
김나라 김소희 김지우 이소희 이영한 이학주

2024.06.27

01 팀원 및 프로젝트 소개

02 데이터 수집

03 EDA 데이터분석

04 추정 득점 예측 모델

05 최적 라인업 추천

06 발전방향



01 팀원 및 프로젝트 소개

업무 분담



김나라

KT 데이터 수집 및 전처리
관련 연구 조사
검증작업
모델링



김소희 (발표)

삼성/한화 데이터 수집 및 전처리
관련 연구 조사
검증작업
모델링



김지우 (팀장)

두산/키움 데이터 수집 및 전처리
관련 연구 조사 및 선행연구자 컨택
검증작업
모델링



이소희 (발표)

SSG/롯데 데이터 수집 및 전처리
관련 연구 조사
검증작업
모델링



이영한

LG/NC 데이터 수집 및 전처리
관련 연구 조사
검증작업
모델링



이학주

기아 데이터 수집 및 전처리
관련 연구 조사
검증작업
모델링

프로젝트 일정



목적

- 데이터 분석을 통해 **최적의 타순**을 도출하여 팀의 경기 **승률을 높임**
- 코칭스태프의 직관에 의존하는 기존 타순 결정 방식의 문제점에 따른 **데이터 기반 타순 결정의 필요성**
- 야구팬들에게 **데이터 기반의 야구 분석**에 대한 관심과 이해도를 증진 시키고자 함

타겟



감독/코치



선수



야구팬

분석개요 및 활용 라이브러리



야구 용어 정리

타순	분류
1번 2번	상위타선
3번 4번 5번	중심타선
6번 7번 8번 9번	하위타선

타자가 1루, 2루, 3루를 지나 홈까지 돌아오면 득점!

타자 공을 치는 선수

투수 공을 던지는 선수

포수 공을 받는 선수

출루율 타자가 출루한 비율

장타율 타자의 타격이 얼마나 강력한지를 나타내는 지표

도루 주자가 투수와 포수가 공을 던지는 동안 다음 베이스로 성공적으로 진루하는 것

득점권 타율 득점권(2루, 3루)에 주자가 있을 때 타자의 타율

홈런 타자가 친 공이 외야 펜스를 넘어가면서 주자가 모두 홈으로 들어와 득점을 얻는 것



야구 용어 정리

타순	분류
1번 2번	상위타선
3번 4번 5번	중심타선
6번 7번 8번 9번	하위타선



기존 라인업

상위타선 : 출루율, 주루 능력

중심타선 : 장타율

하위타선 : 출루율



02 데이터 수집

KBO 10개구단 2019~2024.6.24
출처 : KBO 기록실, 스탯티즈

hitter

kiwoom_hitter_2024.csv

선수명	팀명	타율	경기	타석	타수	득점	...	장타율	출루율	출루율 +장타율	멀티히트	득점권 타율	대타타율
도슨	키움	0.355	64	289	262	48	...	0.553	0.412	0.965	29	0.288	0.5
김혜성	키움	0.336	60	270	241	45	...	0.527	0.4	0.927	22	0.4	0
김건희	키움	0.321	20	63	56	5	...	0.511	0.387	0.898	19	0.317	0.333

hitter_detail

kiwoom_hitter_detail_2024.csv

선수명	팀명	타율	장타	땅볼	뜬공	땅볼/뜬공	결승타	볼넷/삼진	투구수/타석	순수 장타율	추정득점
도슨	키움	0.355	32	61	69	0.88	6	0.6	3.74	0.198	52.2
김혜성	키움	0.336	24	60	76	0.79	5	0.88	3.94	0.191	50.5
김건희	키움	0.321	3	11	8	1.38	0	0.3	3.81	0.008	8.1

batting_order

kiwoom_batting_order_2024.csv

선수명	팀명	타율	타수	안타	2루타	3루타	홈런	타점	볼넷	사구	삼진	병살타	타순
이용규	키움	0.304	92	28	3	0	1	5	14	3	18	1	1번
도슨	키움	0.354	268	95	22	2	9	36	25	2	40	5	2번
김혜성	키움	0.350	234	82	12	2	9	39	24	4	21	3	3번

* hitter에서 10경기 이상, 31타수 이상, batting_order에서 10타수 이상 데이터만 사용

defense

kiwoom_defense_2024.csv

선수명	팀명	포지션	수비 승리 기여도	경기	선발 경기	수비 이닝	실책	견제사	푼아웃	어시스트	병살	수비율	...
김재현	키움	포수	0.354	58	43	410 1/3	6	1	316	28	5	0.983	...
김혜성	키움	2루수	1.001	56	55	478 2/3	8	0	118	166	42	0.973	...
최주환	키움	1루수	-0.047	54	50	445 1/3	3	0	395	25	44	0.993	...

runner

kiwoom_runner_2024.csv

선수명	팀명	경기	도루횟수	도루성공	도루실패	도루성공률	주루사	견제사
김혜성	키움	60	19	17	2	89.5	3	0
도순	키움	64	4	2	2	50	3	0
송성문	키움	66	2	2	0	100	2	1

Data Volume (2019~2024, 10개 구단)

batting order : (12041, 14) , defense : (1703, 18)

hitter : (1781, 26), hitter detail : (1842, 13), runner : (1522, 9)

추정 득점(XR)공식

$$\begin{aligned} & (\text{안타} + \text{볼넷} - \text{도루실패} + \text{사구} - \text{병살타}) \\ & \times \{ 1\text{루타} \times 1.125 + (1.69 \times 2\text{루타}) + (3.02 \times 3\text{루타}) + (3.73 \times \text{홈런}) \\ & + 0.29 \times (\text{볼넷} + \text{사구} - \text{고의사구}) + 0.492 \times (\text{희생플라이} + \text{희생번트}) + 0.07 \times \text{도루} - 0.04 \times \text{도루 실패} \} \end{aligned}$$

타수 + 볼넷 + 사구 + 희생플라이 + 희생번트

득점과 **상관관계가 0.95 이상** 높은 수준
KBO에서 공식적으로 사용되고 있는 지표



03 EDA 데이터분석

타선 유형별로 어떤 능력이 중요할까?


1. 앞 타자가 잘 치면 뒷 타자는 더 잘 칠까?

<출루율과 장타율의 상관관계>

앞 타자의 **출루율 높을** 때 뒷 타자가 **장타 확률**이 큼

- 높은 출루율 - 장타율 : **80% 이상**
- 낮은 출루율 - 장타율 : 50~70%

<출루율과 장타율의 상관관계>



Q. 하위타자의 출루율과
상위타자의 장타율의
상관관계가 가장 크다?

1. 앞 타자가 잘 치면 뒷 타자는 더 잘 칠까?


<타순별 출루율>

년도	상위타선	중심타선	하위타선
2019	0.352	0.365	0.366
2020	0.370	0.381	0.383
2021	0.362	0.379	0.375
2022	0.362	0.359	0.378
2023	0.358	0.375	0.372
평균	0.361	0.372	0.375

하위타선의 평균 출루율이 가장 높음

상위타선에 장타력이 좋은 선수 배치하면 시너지 효과 기대

<타순 유형에 따른 평균 출루율 비교>




2. 앞 타자가 도루를 잘 하면 뒷 타자의 타율이 증가할까?

<앞 타자의 도루 능력에 따른 평균 타율>

년도	앞의 도루능력 👍	앞의 도루능력 👎
2019	0.255	0.128
2020	0.275	0.226
2021	0.264	0.192
2022	0.249	0.203
2023	0.262	0.196
평균	0.261	0.189

<연도별 평균타율 비교>




도루능력이 좋은 타자들이 앞에 배치될 경우 뒤 타자의 평균 타율 증가


2. 앞 타자가 도루를 잘 하면 뒷 타자의 타율이 증가할까?

<타선별 도루능력과 추정득점 간 상관관계>

도루 능력은 **상위타선**의 중요한 지표



<연도별 중심타선 타율 비교>




상위타선의 **도루능력이** 좋으면 중심타선의 **타율이** 증가

3-1. 득점권 타율이 높은 타자를 중심타선에 배치하면 총 추정득점이 증가할까?

<타순 배치에 따른 추정득점>

년도	상위타선	중심타선	하위타선
2019	14.69	28.70	15.17
2020	25.69	39.47	14.69
2021	25.69	32.56	27.19
2022	9.42	38.63	12.92
2023	27.11	27.46	9.42
평균	20.52	33.36	15.88

<연도별 추정득점 비교>



주 : 상위타선, 중심타선, 하위타선은 득점권 타율이 높은 타자들을 배치한 위치


득점권 타율이 높은 선수가 중심타선에 배치 될 경우 추정득점이 가장 높음

3-2. 장타율이 높은 타자를 중심타선에 배치하면 총 추정득점이 증가할까?

<타순 배치에 따른 추정득점>

년도	상위타선	중심타선	하위타선
2019	33.22	38.24	17.03
2020	49.50	44.03	21.83
2021	24.98	55.10	14.41
2022	32.87	45.65	16.16
2023	28.41	45.69	16.51
평균	33.80	45.74	17.19

<연도별 추정득점 비교>




주 : 상위타선, 중심타선, 하위타선은 득점권 타율이 높은 타자들을 배치한 위치 / 타선당 상위 10% 선수들만 선정하였음

장타율이 높은 선수가 중심타선에 배치 될 경우 추정득점이 가장 높음


3-3. 홈런이 많은 타자를 중심타선에 배치하면 총 추정득점이 증가할까?

<홈런과 추정득점의 관계>


상위타선
0.69



중심타선
0.92



하위타선
0.74




중심타선의 홈런개수는 추정득점에 높은 상관관계를 보임

4. 수비승리기여도가 높은 선수를 하위타선 배치 시 추정실점이 낮아질까?

< 추정 실점 공식 : $\text{추정실점} = (\text{리그 평균 실점} * \text{경기수}) - (\text{수비승리기여도} * \text{조정계수}) / \text{경기수} * \text{시즌 총 경기수}$ >

<KBO 10구단 연도별 평균 추정실점 비교>



하위타선의 추정실점이 기타(상위/중심타선)의 추정실점보다 낮음

추정 득점과의 상관계수

출루율	장타율	홈런	득점권타율	도루허용	수비 승리 기여도
0.35	0.46	0.56	0.33	0.33	0.10

타자/타선별 지표

1번타자 : 출루율, 도루허용

2번타자 : 홈런, 장타율, 출루율, 도루허용

중심타선 : 홈런, 장타율, 득점권타율

하위타선 : 출루율, 수비 승리기여도

상관계수 평균

0.34

0.425

0.45

0.225



04 추정 득점 예측 모델

모델 학습

DATA

KBO_top5.csv

2019~2023 5년간
상위 5개팀 데이터로 학습

Feature

출루율, 장타율, 홈런, 득점권타율,
도루허용, 수비 승리 기여도
가설확인에서 확인한 각 타선 유형별 주요 지표

Target

추정득점

관련 연구



한국융합과학회지

Vol.12 No.11 pp. 261-275 November 2023

<https://doi.org/10.24826/KSCS.12.11.17>

Korean Journal of Convergence Science

ISSN 2671-7395(Print), 2671-7409(Online)

<http://www.kscs.kr>

타순별 통계와 기계학습의 회귀 모델을 활용한 한국 프로야구에서 팀 득점력 개선

신동윤₁ · 이수안₂ · 김진호₃

₁주식회사 클로잇 AM-Tech그룹 수석, ₂세명대학교 컴퓨터학부 교수, ₃강원대학교 컴퓨터공학과 교수

Improving Team's Scoring Ability in KBO(Korea Baseball Organization) League using Each Batting Order's Statistics and Regression Model of Machine Learning

Shin, Dong Yun₁ · Lee, Suan₂ · Kim, Jinho₃

₁Principal Software Engineer, AM-Tech Group, CloIT Co., Ltd.

₂Professor, School of Computer Science, Semyung University, Jecheon

₃Professor, Department of Computer Science and Engineering, Kangwon National University, Chuncheon

“이러한 회귀 분석을 위하여, 야구 관련 연구에서 예측 성능이 뛰어나다고 증명된 모델들을 사용하여 예비 팀 득점 예측 모델을 만들었다.

한정섭, 정다현, 김성준(2022)은 *XGBoost(Extreme Gradient Boosting)*를, 신동윤과 김진호(2023)는 *SVR(서포트 벡터 머신 회귀)*과 *Ridge*가 성능이 우수하다고 하였다.

김민택, 구자환, 김응모 (2019)는 *Random Forest*와 *Gradient Boosting*을, 김태훈, 임성원, 고진광, 이재학(2020)은 *KNN(K-Nearest Neighbor)*과 *AdaBoost(Adaptive Boosting)*가 뛰어난 예측력을 보여주었다고 하였다.”

-논문 내용 中-

모델 성능비교

모델	MSE	RMSE	MAE	R2
XGB	294.06	17.15	11.77	0.69
SVR	992.15	31.50	19.78	-0.05
Ridge	591.58	24.32	17.93	0.38
GradientBoosting	228.05	15.10	9.85	0.76
RandomForest	223.41	14.95	9.44	0.76
KNN	506.76	22.51	14.52	0.46
AdaBoost	722.84	26.89	19.14	0.24
LGBM	226.66	15.06	10.06	0.76
LinearRegression	581.90	24.12	17.96	0.39
Lasso	589.28	24.28	18.07	0.38

관련 연구자료에서 언급된 모델을
대상으로 실험

MSE, RMSE, MAE가 낮고
R2가 높은

RandomForest
Regressor
최종 선택

최적 파라미터 찾기

하이퍼파라미터 그리드 설정

```
param_grid = {  
    'n_estimators': [50, 100, 150, 200],  
    'max_depth': [None, 10, 20, 30, 40],  
    'max_features': [0.3, 0.5, 0.7, 1.0]  
}
```

모델 초기화

```
rf = RandomForestRegressor(random_state=42)
```

그리드 서치 설정

```
grid_search = GridSearchCV(estimator=rf,  
    param_grid=param_grid, cv=5, n_jobs=-1, verbose=2)
```

**Grid Search를 통한
Random Forest
Regressor의
최적 파라미터 찾기**



05 최적 라인업 추천

데이터 최종 업데이트 : 2024.06.24

키움 히어로즈



6월 24일 기준 10위팀. 라인업 개선 방향 제시

중심타선 타자 선발

장타율*0.46 + 득점권 타율*0.33 + 홈런*0.56



김혜성

장타율 0.523
득점권 타율 0.383
홈런 10개



도슨

장타율 0.544
득점권 타율 0.291
홈런 9개



송성문

장타율 0.508
득점권 타율 0.333
홈런 9개

KIWOOM

장타율 0.386
득점권 타율 0.274
팀 홈런 56개

2번 타자 선발

장타율*0.46 + 출루율*0.35
+ 도루*0.33 + 홈런*0.56

장타율 0.479
출루율 0.402
도루 1개
홈런 4개



이형종

KIWOOM

장타율 0.386
출루율 0.345
팀 도루 27개
팀 홈런 56개

1번 타자 선발

출루율*0.35 + 도루*0.33

출루율 0.421
도루 2개



이용규

하위타선 타자 선발

출루율*0.35 + 수비 승리 기여도*0.10



김건희

출루율 0.374

수비 기여도 -0.156



이주형

출루율 0.362

수비 기여도 0.018



고영우

출루율 0.342

수비 기여도 0.146



최주환

출루율 0.261

수비 기여도 -0.128

KIWOOM

출루율 0.345 수비 승리 기여도 -0.613

타자 선발 KEY POINT

수비 포지션을 고려하기 위해
상위, 중심타선에서 포수가 없으면
하위타선에 점수가 가장 높은 포수를 선택

포지션 누락(포수 제외)이 있다면 하위타선에서 가장 점수가
낮은 선수를 제외하고 누락된 포지션의 선수 중
점수가 가장 높은 선수를 추가



최적 라인업

중심타선 6개 조합 X 하위타선 24개 조합 = 144개 조합

144개 라인업 조합에 대해 추정 득점 예측 모델을 통해
예상 추정 득점값 추출
가장 점수가 높은 라인업을 최적 라인업으로 추천

타자 선발 기준

기존 라인업

상위타선 : 출루율, 주루 능력

중심타선 : 장타율

하위타선 : 출루율



퍼펙트게임 라인업

상위타선 : 출루율, 도루, 장타율

중심타선 : 장타율, 득점권타율, 홈런

하위타선 : 출루율, 수비 능력



기준 라인업

1	이용규	좌익수
2	도슨	중견수
3	김혜성	2루수
4	이주형	우익수
5	최주환	1루수
6	송성문	3루수
7	변상권	지명타자
8	김재현	포수
9	이재상	유격수

추정 득점 : 29.11점

최적 라인업

1	이용규	좌익수
2	이형종	우익수
3	김혜성	2루수
4	송성문	3루수
5	도슨	중견수
6	고영우	유격수
7	김건희	포수
8	이주형	지명타자
9	최주환	1루수

추정 득점 : 38.53점 ³⁸

추정득점
약 9.4점 ↑

기준 라인업

1	홍창기	우익수
2	문성주	좌익수
3	김현수	지명타자
4	오스틴	1루수
5	문보경	3루수
6	박동원	포수
7	구본혁	유격수
8	박해민	중견수
9	신민재	2루수

추정 득점 : 52.83점



→ 추정득점
약 0.1 점 ↑

최적 라인업

1	문성주	좌익수
2	홍창기	우익수
3	오스틴	1루수
4	문보경	3루수
5	박동원	포수
6	오지환	유격수
7	박해민	중견수
8	신민재	2루수
9	김현수	지명타자

추정 득점 : 52.93점 ³⁹



06 발전방향

발전 방향

현재는 1군 명단에 없는 선수들 (부상, 부진 등)도 최적 라인업에 포함
선수 등록, 말소 리스트를 통해 **1군 명단 선수로**
최적 라인업 구성

구장별 파크팩터, 날씨 조건, 상대 선발투수 정보 등
다른 지표들도 추가 (**feature 추가**)해서
최적 라인업 구성

참고자료

- 신동윤, 이수안, & 김진호. (2023). 타순별 통계와 기계학습의 회귀 모델을 활용한 한국 프로야구에서 팀 득점력 개선. *한국융합과학회지*, 12(11), 261-275.
- 황일회, 조현주, 김대영, & 이민석. (2011). MARKOV CHAIN 을 이용한 한국프로야구 분석 및 최적 타순 계산을 위한 모델연구. *대한산업공학회 추계학술대회 논문집*, 821-828.
- 토아일당. (2015). 최적 타순에 관한 통계적기준 - 세이버메트릭스 가이드. *Baseball-in-Play*. <https://baseball-in-play.com/220>
- SPORTS KU. (2020). Baseball Team Fight Tactic - 라인업, 타순의 미학. *Column*. <https://blog.naver.com/sportsku/222090853729>



감사합니다

데이터톤 퍼펙트게임
김나라 김소희 김지우 이소희 이영한 이학주



QnA

데이터 범위 설정

타자 데이터에서 10경기 이상, 31타수 이상
타순 데이터에서 10타수 이상 조건

* 정규타석 = 경기수 X 3.1

선수명	팀명	타율	경기	타석	타수	득점	...	장타율	출루율	출루율 +장타율	멀티히트	득점권 타율	대타타율
김대원	LG	1.000	6	1	1	1	...	1.000	1.000	2.000	0	0.000	1.000
백두산	롯데	0.000	1	1	1	0	...	0.000	0.000	0.000	0	0.000	0.000

선수명	팀명	타율	타수	안타	2루타	3루타	홈런	타점	볼넷	사구	삼진	병살타	타순
이원석	키움	1.000	1	1	0	0	0	0	0	0	0	0	1번
김혜성	키움	0.000	1	0	0	0	0	0	0	0	0	0	6번

타선 데이터 채우기

선수명	팀명	타율	타수	안타	2루타	3루타	홈런	타점	볼넷	사구	삼진	병살타	타순
김혜성	키움	0.214	14	3	1	0	1	1	0	0	4	0	1번
김혜성	키움	-	-	-	-	-	-	-	-	-	-	-	2번
김혜성	키움	0.348	247	86	13	2	9	39	29	4	21	4	3번
김혜성	키움	-	-	-	-	-	-	-	-	-	-	-	4번
김혜성	키움	-	-	-	-	-	-	-	-	-	-	-	5번
김혜성	키움	-	-	-	-	-	-	-	-	-	-	-	6번
김혜성	키움	-	-	-	-	-	-	-	-	-	-	-	7번
김혜성	키움	-	-	-	-	-	-	-	-	-	-	-	8번
김혜성	키움	-	-	-	-	-	-	-	-	-	-	-	9번

삭제

타선 데이터 채우기

선수명	팀명	타율	타수	안타	2루타	3루타	홈런	타점	볼넷	사구	삼진	병살타	타순
김혜성	키움	0.214	14	3	1	0	1	1	0	0	4	0	1번
김혜성	키움	-	-	-	-	-	-	-	-	-	-	-	2번
김혜성	키움	0.348	247	86	13	2	9	39	29	4	21	4	3번

각 타순의 타석수를 가중치로 하여 빈 타순에 대한 기록 추가

```
1 # 가중 평균 계산 함수
2 def calculate_weighted_average(records):
3     weighted_avg = {}
4     total_weight = records['타수'].sum()
5     for column in records.columns:
6         if column not in ['선수명', '팀명', '타순'] and pd.api.types.is_numeric_dtype(records[column]):
7             weighted_avg[column] = (records[column] * records['타수']).sum() / total_weight
8     return weighted_avg
```

타선 데이터 채우기

선수명	팀명	타율	타수	안타	2루타	3루타	홈런	타점	볼넷	사구	삼진	병살타	타순
김혜성	키움	0.214	14	3	1	0	1	1	0	0	4	0	1번
김혜성	키움	0.340	234	81	12	1	8	36	27	3	20	3	2번
김혜성	키움	0.348	247	86	13	2	9	39	29	4	21	4	3번
김혜성	키움	0.340	234	81	12	1	8	36	27	3	20	3	4번
김혜성	키움	0.340	234	81	12	1	8	36	27	3	20	3	5번
김혜성	키움	0.340	234	81	12	1	8	36	27	3	20	3	6번
김혜성	키움	0.340	234	81	12	1	8	36	27	3	20	3	7번
김혜성	키움	0.340	234	81	12	1	8	36	27	3	20	3	8번
김혜성	키움	0.340	234	81	12	1	8	36	27	3	20	3	9번

가중치 반영

추정득점과의 상관계수

출루율	장타율	홈런	득점권타율	도루허용	수비 승리 기여도
0.35	0.46	0.56	0.33	0.33	0.10

중심타선 : 장타율*0.46 + 득점권 타율*0.33 + 홈런*0.56
 2번타자 : 장타율*0.46 + 출루율*0.35 + 도루*0.33 + 홈런*0.56
 1번타자 : 출루율*0.35 + 도루*0.33
 하위타선 : 출루율*0.35 + 수비 승리 기여도*0.10

선수명	팀명	...	장타율	득점권 타율	홈런	...	장타율_표준화	득점권 타율_표준화	홈런_표준화	중심타선 합산 지표
김혜성	키움	...	0.523	0.383	10	...	1.592	0.890	2.235	2.278
도슨	키움	...	0.544	0.291	9	...	1.790	0.090	1.932	1.935
송성문	키움	...	0.508	0.333	9	...	1.450	0.455	1.932	1.899